



Universidad del Cauca

INFORME PARCIAL DE PROYECTO

Apropiación de tecnologías de reconstrucción y renderizado digital de objetos 3D para la promoción del patrimonio cultural relacionado con los volantes de huso y la producción textil de las sociedades prehispánicas del suroccidente Colombiano.

Proyecto de desarrollo interno ID 6292.

ANEXO 2

Evaluación de tecnologías de reconstrucción y renderizado digital de objetos 3D para la promoción del patrimonio cultural relacionado con los volantes de huso y la producción textil de las sociedades prehispánicas del suroccidente Colombiano.

Autores:

Daniela Andrea Diaz Medina
Jaime Esteban Villamizar Rojas
Carlos Hernán Tobar Arteaga

Grupos de investigación:

Grupo de Ingeniería Telemática.

UNIVERSIDAD DEL CAUCA

Vicerrectoría de Investigaciones

Popayán, noviembre de 2025

RESUMEN

El modelado 3D de objetos arqueológicos, se ha fortalecido con el pasar de los años, siendo una herramienta muy útil para la conservación, restauración y el estudio de piezas históricas. Este proceso no solo permite la digitalización precisa de artefactos, sino que también proporciona una plataforma para su análisis detallado sin riesgo de daño a los objetos originales. El avance en las tecnologías de fotogrametría y técnicas de reconstrucción 3D, como Gaussian Splatting, ha transformado la manera en que los expertos interactúan con el patrimonio cultural, ofreciendo una forma eficiente y no invasiva de preservar y estudiar estos objetos.

La fotogrametría, en particular, es una de las técnicas más utilizadas en la digitalización de artefactos arqueológicos. Fundamentalmente, la fotogrametría se basa en la medición precisa de los objetos mediante imágenes fotográficas [27]. A través de un conjunto de fotografías tomadas desde múltiples ángulos, es posible crear un modelo 3D detallado del objeto, capturando tanto su forma como sus texturas y características superficiales. Este proceso, que puede realizarse con equipos estándar de fotografía digital, se ha visto significativamente mejorado gracias a los avances tecnológicos, como el emparejamiento de imágenes a nivel de subpíxeles y el uso de algoritmos avanzados de procesamiento [27].

Los recientes avances en la fotogrametría y en la reconstrucción 3D, como el uso de Structure from Motion (SfM) [30], han permitido obtener datos de superficies 3D extremadamente densos y precisos en un corto período de tiempo, lo que hace que esta técnica sea aún más accesible y útil para proyectos de preservación patrimonial. La fotogrametría no solo es una herramienta eficiente para la digitalización, sino que también es compatible con técnicas de modelado más complejas, como el Gaussian Splatting, que se usa en este proyecto para modelar objetos arqueológicos de la Ceramoteca del Museo de Historia Natural de la Universidad del Cauca.

El propósito de este anexo es describir el proceso completo de modelado 3D de tres volantes de huso, y detallar cómo se aplica la técnica de Gaussian Splatting en este contexto.

1 Representación 3D basada en Gaussian Splatting

3D Gaussian Splatting (3DGS) es una técnica avanzada para la síntesis de vistas novedosas y la reconstrucción 3D que se fundamenta en una representación explícita de la escena. A diferencia de los métodos implícitos, modela las escenas como una colección de primitivas discretas, específicamente elipsoides anisotrópicos 3D, cada una descrita por una distribución Gaussiana. Cada Gaussiana almacena un conjunto de atributos clave: su posición (media) para la localización espacial, una matriz de covarianza que define su forma, escala y rotación para modelar la geometría local, un valor de opacidad para controlar la transparencia, y un conjunto de coeficientes de armónicos esféricos para representar eficientemente el color dependiente del punto de vista, como los efectos de especularidad. La técnica logra una renderización de alta fidelidad y en tiempo real a través de un proceso de rasterización diferenciable, conocido como splatting, que proyecta eficientemente estas Gaussianas 3D en el plano de la imagen 2D; su color se calcula mediante una composición ordenada por profundidad de todas las Gaussianas que cubren dicho píxel. Este enfoque, que elimina la necesidad de un muestreo denso de puntos, constituye una de sus principales ventajas arquitectónicas y establece una diferencia fundamental con otras técnicas como NeRF.

La ventaja fundamental de 3DGS en rendimiento se origina en su cambio de paradigma de renderizado: abandona el costoso renderizado volumétrico de NeRF, que requiere un muestreo intensivo de puntos a lo largo de cada rayo, en favor de una rasterización basada en proyección, un proceso altamente optimizable y afín a las arquitecturas de GPU modernas. Esta distinción es la que permite sus ventajas arquitectónicas, las cuales se manifiestan en varios aspectos clave. En cuanto al modelo de representación, 3DGS emplea un enfoque explícito (un conjunto discreto de Gaussianas), mientras que NeRF utiliza un modelo implícito (una red neuronal continua que representa la escena). Esta diferencia se extiende al proceso de renderización: 3DGS utiliza la rasterización basada en proyección, que es computacionalmente eficiente, mientras que NeRF depende del renderizado volumétrico. Adicionalmente, en el manejo de la opacidad, 3DGS modela los valores de opacidad directamente para cada Gaussiana, mientras que NeRF los deriva indirectamente a partir de un campo de densidad. En conjunto, estas diferencias otorgan a 3DGS una ventaja decisiva en eficiencia, permitiendo una convergencia de entrenamiento mucho más rápida y velocidades de renderizado en tiempo real (≥ 30 FPS a resoluciones de 1080p), superando así la lentitud inherente de NeRF. Esta eficiencia superior hace que 3DGS sea especialmente adecuado para aplicaciones que demandan interactividad y procesamiento rápido.

Las características intrínsecas de 3DGS la convierten en una técnica especialmente apropiada para la reconstrucción digital de objetos arqueológicos. En primer lugar, su capacidad para generar reconstrucciones con altos niveles de detalle y calidad fotorrealista es fundamental para la preservación digital del patrimonio. Esta fidelidad permite capturar con gran precisión las geometrías complejas y las texturas sutiles de los artefactos históricos, creando un registro digital fiel para su estudio y conservación. Este es un requisito indispensable para crear archivos digitales precisos que puedan ser utilizados para la investigación académica, la planificación de la conservación y la divulgación del patrimonio cultural a una audiencia global.

2 Modelo matemático de 3DGS

El modelo matemático de 3DGS se fundamenta en una representación explícita de la escena mediante un conjunto de Gaussianas 3D anisotrópicas, que actúan como primitivas geométrico-radiométricas optimizables. Cada Gaussiana se define mediante una media μ , una covarianza Σ que determina su forma elipsoidal, una opacidad α y un color dependiente de la vista expresado con Armónicos Esféricos. La covarianza se parametriza mediante una descomposición $\Sigma = R S S^T R^T$, donde R es una rotación (expresada como cuaternión) y S una escala diagonal, lo que garantiza estabilidad numérica y positividad semidefinida durante la optimización.

El pipeline de renderizado se basa en rasterización por splatting, evitando el muestreo de rayos. Cada Gaussiana se proyecta al plano de la cámara mediante una transformación de la covarianza 3D a 2D: $\Sigma' = (J W \Sigma W^T J^T)_{1:2,1:2}$,

y se rasteriza como una elipse 2D. Las Gaussianas que cubren cada tesela de la imagen se ordenan por profundidad, y el color final del píxel se obtiene mediante composición alfa:

$$C = \sum_i c_i \alpha_i \prod_{j < i} (1 - \alpha_j),$$

donde α_i depende de la densidad de la proyección y de la opacidad intrínseca de la primitiva.

El aprendizaje del modelo ajusta todos los parámetros de las Gaussianas para reproducir un conjunto de imágenes multivista. La optimización se guía por una pérdida combinada que integra $L1$ y DSSIM, equilibrando precisión cromática y fidelidad estructural. Durante el entrenamiento se aplica un control adaptativo de densidad, que refina dinámicamente la distribución de Gaussianas mediante clonación, división y poda, en función de los gradientes de posición y los valores de opacidad.

En conjunto, este marco matemático combina una representación explícita, un pipeline de rasterización eficiente en GPU y una optimización adaptativa, permitiendo una reconstrucción fotorrealista de escenas 3D con renderizado en tiempo real y alto nivel de detalle.

3 Pipeline general de 3DGS

El método 3DGS constituye un cambio de paradigma en la síntesis de nuevas vistas, al resolver de forma decisiva el compromiso entre fotorrealismo y rendimiento en tiempo real que limitaba a métodos volumétricos como NeRF. Su eficiencia proviene de optimizar directamente un conjunto de gaussianas 3D explícitas, en lugar de depender de una red neuronal densa. El pipeline se articula en cuatro fases: inicialización, optimización, renderizado y refinamiento adaptativo.

3.1 Inicialización

Esta fase establece una primera aproximación geométrica de la escena. El sistema genera un conjunto inicial de gaussianas a partir de una nube de puntos dispersa, típicamente obtenida mediante Structure-from-Motion (SfM). Alternativamente, puede emplearse una inicialización aleatoria en el espacio 3D. El enfoque es deliberadamente flexible: 3DGS no requiere una reconstrucción inicial densa o precisa. La representación comienza siendo ligera y se complejiza de forma dinámica durante el entrenamiento, lo que la hace robusta frente a nubes de puntos incompletas o ruidosas.

3.2 Optimización de atributos

Es el núcleo del aprendizaje. Cada gaussiana se ajusta para que su proyección reproduzca con alta fidelidad las imágenes de entrada. Los parámetros optimizados son:

- Posición (μ): centro de la gaussiana.
- Covarianza (Σ): define forma y orientación. Se optimiza de manera estable mediante: Rotación (q): cuaternión. Escala (s): vector de escalas principales. Esta descomposición evita restricciones explícitas sobre Σ .
- Opacidad (α): controla la contribución de cada primitiva.
- Color (SH): coeficientes de Armónicos Esféricos para modelado dependiente del punto de vista.

A diferencia de NeRF, que aprende una función implícita mediante una red neuronal, 3DGS optimiza directamente los atributos de su representación discreta, logrando un entrenamiento más eficiente y rápido.

3.3 Renderizado por splatting

El renderizado es la clave del rendimiento en tiempo real. Consiste en proyectar y componer las gaussianas en la imagen 2D mediante tres pasos:

1. Proyección: cada gaussiana 3D se transforma en una elipse 2D al proyectar su media y covarianza.
2. Rasterización por teselas: la imagen se divide en parches (p. ej., 16×16). Para cada tesela se identifican las gaussianas que la cubren y se ordenan por profundidad.
3. Composición alfa: los colores y opacidades se combinan secuencialmente mediante alpha blending para obtener el color final del píxel.

Este mecanismo evita completamente el volumetric ray marching de NeRF, sustituyéndolo por una rasterización ligera y altamente paralelizable, lo que habilita renderizado en tiempo real con calidad fotorrealista.

3.4 Refinamiento adaptativo

Durante el entrenamiento, el sistema ajusta dinámicamente la estructura del conjunto de gaussianas mediante densificación y poda, guiadas por los gradientes de la fase de optimización.

- Densificación: se aplica cuando los gradientes proyectados son elevados, señal de que una gaussiana intenta cubrir una región demasiado compleja. Se crean nuevas primitivas mediante clonación o división.
- Poda: elimina gaussianas redundantes o irrelevantes, como aquellas con opacidad muy baja o tamaño excesivo.

Además, la estrategia de reinicio periódico de opacidad (soft garbage collection) suprime primitivas obsoletas o inestables, estabilizando la representación. Este mecanismo adaptativo permite que el modelo evolucione hacia una escena rica en detalle, eficiente en memoria y estable durante el renderizado.

4 Limitaciones y desafíos técnicos

A pesar de su rendimiento en tiempo real y de su capacidad para generar vistas fotorrealistas, 3DGS presenta limitaciones derivadas directamente de su naturaleza como representación explícita y altamente discreta. Estas limitaciones impactan la fidelidad geométrica, la escalabilidad computacional y la capacidad de edición.

En primer lugar, la representación mediante gaussianas independientes y sin conectividad topológica impide obtener superficies continuas y limpias, dificultando la extracción de mallas y comprometiendo la precisión geométrica, especialmente en escenas con materiales reflectantes o especulares. Este carácter discreto también conduce a efectos como aliasing y floaters, no solo por sobre-reconstrucción, sino por la tendencia del proceso de optimización a densificar en exceso para minimizar la pérdida en el espacio de imagen.

Además, 3DGS depende críticamente de datos multivista de alta calidad con poses de cámara precisas. En entornos “in-the-wild”, donde abundan oclusiones, movimiento, variaciones de iluminación y ruido en la calibración, su rendimiento se degrada notablemente. A diferencia de NeRF, que puede amortiguar estas inconsistencias mediante vectores de incrustación por imagen, 3DGS carece de mecanismos equivalentes de compartición de parámetros, lo que limita su robustez.

Las exigencias computacionales y de almacenamiento constituyen otro desafío. Una escena típica requiere almacenar millones de gaussianas, lo que se traduce en cientos de megabytes o incluso gigabytes, dificultando su uso en dispositivos de borde. Asimismo, en escenarios de gran escala y alta resolución, la rasterización se vuelve un cuello de botella debido al enorme número de interacciones gaussiana–tesela, cuyo coste crece con la complejidad y la resolución de la escena.

Por último, 3DGS enfrenta dificultades en la representación de escenas dinámicas y en el desacoplamiento preciso entre geometría, textura e iluminación. Esta falta de modularidad complica la edición controlada de la escena y, con frecuencia, obliga a una reoptimización costosa tras cualquier modificación sustancial, reduciendo la flexibilidad del sistema para tareas de edición avanzadas.

5 Modelado 3D de volantes de huso usando 3D Gaussian Splatting

A continuación, se describe el método de 3DGS adaptado al modelado 3D de volantes de huso:

5.1 Selección de los volantes de huso en la Ceramoteca del Museo de Historia Natural de la Universidad del Cauca

El primer paso para llevar a cabo estos modelos fue la selección de los objetos arqueológicos que serían representados en una escena 3D. Para este proyecto, se eligieron tres volantes de huso con diferentes características y bajo ciertos criterios específicos. La selección incluyó objetos con variabilidad en tamaños (altura, diámetro) y formas (cónico, semicilíndrico, discoidal), así como diferentes patrones y colores en sus superficies. Asimismo, se consideraron distintas condiciones de conservación, eligiendo a propósito un objeto con algunos deterioros y otros muy bien conservados. En pocas palabras, se realizó una selección premeditada con el fin de observar el comportamiento del método 3DGS bajo distintas condiciones.

5.2 Captura fotográfica utilizando protocolos de fotogrametría

Una vez seleccionados los objetos, se procedió a la captura de imágenes para el modelado 3D. La fotogrametría fue clave en este paso, ya que proporcionó la información visual necesaria para reconstruir el modelo 3D. Para ello se siguieron los siguientes protocolos:

Posicionamiento del objeto: Cada volante de huso se ubicó en un entorno controlado para evitar interferencias visuales y asegurar la calidad de las imágenes, se utilizó un fondo neutro y una base oscura, y el objeto fue iluminado con una luz cálida para que no se puedan generar sombras o reflejos que pudieran interferir con la captura de detalles.

Captura de imágenes: Se tomaron videos del objeto desde dos ángulos diferentes alrededor del mismo, garantizando una cobertura completa y detallada. Este proceso siguió el principio básico de la fotogrametría, el cual se basa en la superposición de imágenes desde diferentes puntos de vista para generar una nube de puntos densa y precisa. Durante esta fase, se consideraron los siguientes aspectos esenciales, como recomienda Cultural Heritage Imaging [27]:

- **Alta resolución:** Cada video se capturó en alta resolución para garantizar la captura de los detalles más finos, lo cual es crucial para la precisión del modelo 3D generado.
- **Cobertura total del objeto:** Se aseguró que cada parte del objeto estuviera representado en los videos, evitando omitir bordes, texturas y características clave. Esto incluye la necesidad de capturar cada detalle, por mínimo que sea.
- **Consistencia en la iluminación:** Se procuró que la iluminación fuera consistente a lo largo de los videos y que se evitaran sombras o reflejos que pudieran dificultar el procesamiento posterior. La luz se distribuye uniformemente sobre el objeto sin crear contrastes excesivos.

La precisión en la captura de los videos es fundamental para garantizar que los modelos 3D generados reflejen fielmente las características del objeto real y no presenten distorsiones o errores en la representación.

5.3 Preprocesamiento de las imágenes

Tras completar la captura fotográfica, el siguiente paso consistió en el preprocesamiento de las imágenes para prepararlas como entrada para el pipeline de Gaussian Splatting. Este proceso, ejecutado en un entorno con CPU en un computador de la universidad, fue fundamental para garantizar la calidad y coherencia de los datos de entrada.

Inicialmente, los videos capturados fueron procesados con la herramienta FFmpeg para extraer frames individuales. Se ajustó la tasa de extracción para obtener un conjunto de imágenes suficientemente denso que garantizara una superposición óptima entre vistas consecutivas, eliminando al mismo tiempo fotogramas duplicados o borrosos que pudieran introducir ruido en la reconstrucción.

Posteriormente, este conjunto de imágenes se introdujo en el pipeline de COLMAP (Structure-from-Motion). El proceso automatizado del repositorio oficial de Gaussian Splatting ejecutó de manera secuencial las tres etapas críticas de COLMAP:

- Extracción de características SIFT: Se identificaron puntos de interés invariantes en cada una de las imágenes de los volantes de huso.
- Emparejamiento exhaustivo: Se establecieron correspondencias entre las características de todos los pares de imágenes posibles para conectar las diferentes vistas.
- Reconstrucción sparse y Bundle Adjustment: Se trianguló la posición 3D de los puntos para generar una nube de puntos sparse inicial y se refinó simultáneamente la geometría de la escena y los parámetros de las cámaras, minimizando el error de reproyección.

El resultado de este preprocesamiento fue, para cada volante de huso, una nube de puntos 3D sparse y un conjunto de cámaras calibradas, los cuales sirvieron como la geometría inicial y la base de datos de entrenamiento para la siguiente etapa de optimización con Gaussian Splatting.

5.4 Aplicación de 3D Gaussian Splatting

Con la nube de puntos sparse y las cámaras calibradas obtenidas de COLMAP, se procedió a la etapa central de representación 3D mediante la aplicación del algoritmo 3D Gaussian Splatting. El proceso de entrenamiento se diseñó para monitorear la evolución de los modelos en puntos de iteración específicos (3.000, 6.000, 9.000, 12.000 y 30.000 iteraciones), lo que permitió realizar un seguimiento detallado de la convergencia y calidad de la reconstrucción para cada uno de los tres volantes de huso. Todo el proceso se ejecutó utilizando exclusivamente recursos de la GPU del computador proporcionado por la universidad.

La optimización se inició creando una gaussiana 3D por cada punto de la reconstrucción sparse de COLMAP. A partir de esta geometría inicial, el algoritmo optimizó iterativamente los parámetros de cada gaussiana para minimizar la diferencia entre las imágenes renderizadas y las imágenes de entrenamiento originales. Los parámetros optimizados para cada gaussiana fueron:

- Propiedades geométricas: Posición en el espacio 3D, opacidad y una matriz de covarianza anisotrópica que controla la forma y orientación elástica de cada splat.

- Propiedades de apariencia: Coeficientes de spherical harmonics para modelar el color y los efectos de dependencia visual (view-dependant effects), como reflejos especulares sutiles en la superficie cerámica.
- Densidad adaptativa: Mediante un mecanismo de control de densidad, el algoritmo clonó y dividió gaussianas en áreas con alto error de reconstrucción (como bordes tallados o patrones complejos), y las eliminó en zonas donde eran redundantes, refinando automáticamente el nivel de detalle de la escena.

Finalizada la optimización, el modelo resultante para cada volante de huso fue renderizado utilizando la técnica de rasterización basada en tiles, la cual permite la visualización interactiva y la generación de imágenes 2D desde cualquier punto de vista mediante la proyección ordenada y el blending de los splats gaussianos. La calidad de los modelos se evaluó cuantitativamente mediante la métrica PSNR y cualitativamente mediante una inspección visual directa de la fidelidad geométrica y textural.

5.5 Visualización de los render de cada volante de uso




Figura 5.1: Evolución de la reconstrucción 3D de los volantes de huso en diferentes iteraciones del entrenamiento. Se observa la mejora progresiva en detalle geométrico y calidez perceptual a medida que aumentan las iteraciones.

6 Evaluación

Evolución del PSNR




Figura 5.2: Volante 1 (geometría discoidal). Se observa el mejor desempeño inicial con 29.08 dB a las 3,000 iteraciones y una convergencia rápida, alcanzando el 90% del PSNR final en solo 6,000 iteraciones. El PSNR final es de 31.96 dB.




Figura 5.3: Volante 2 (geometría cónica). Muestra el menor PSNR inicial (21.04 dB) y un crecimiento más gradual durante el entrenamiento. Alcanza un PSNR final de 29.02 dB, sugiriendo que la geometría cónica presenta mayor complejidad para la reconstrucción.




Figura 5.4: Volante 3 (geometría semicilíndrica). Presenta la mayor ganancia relativa (+4.89 dB desde 3k a 30k iteraciones) y un crecimiento sostenido durante todo el entrenamiento. Proyecta el mejor PSNR final estimado de 30.1 dB, indicando buena escalabilidad con iteraciones adicionales.

Métricas comparativas finales

Cuadro 5.1: Comparación de métricas de calidad a 30,000 iteraciones para los tres volantes de huso

Métrica	Volante 1 (Discoidal)	Volante 2 (Cónico)	Volante 3 (Semicilíndrico)
PSNR (dB)	31.96	29.02	30.37
SSIM	0.9430	0.8995	0.9387
LPIPS	0.2716	0.1916	0.2452
Tiempo entrenamiento	1:13:55	1:37:29	1:10:15

7 Discusión

A partir del análisis de los resultados obtenidos, se pueden establecer las siguientes conclusiones preliminares:

E ciencia computacional: El Volante 3, con forma semicilíndrica, demostró ser el más eficiente. Logró el segundo mejor PSNR (30.37 dB) en el menor tiempo de entrenamiento (1:10:15). Esto indica que, al tener una complejidad intermedia, este tipo de geometría optimiza de manera más efectiva el balance entre tiempo de procesamiento y calidad de resultados.

Calidad numérica vs. perceptual: En cuanto a la calidad de los volantes, se observa una diferencia interesante entre las métricas utilizadas para medirla. El Volante 1, con forma de disco, logró los mejores valores en las mediciones de calidad numérica, alcanzando un PSNR (Relación Señal-Ruido Pico) de 31.96 dB y un SSIM (Índice Estructural de Similitud) de 0.9430, lo que indica que tiene una calidad más alta desde el punto de vista técnico. Por otro lado, el Volante 2, con forma cónica, obtuvo el mejor valor en el LPIPS (Puntuación de Percepción de la Imagen) con 0.1916, lo que sugiere que tiene una mejor calidad perceptual, es decir, es percibido como de mejor calidad por los observadores, a pesar de tener un PSNR más bajo de 29.02 dB. Esto muestra que, aunque ambos volantes tienen características de calidad diferentes, cada uno sobresale en un aspecto particular.

Impacto de la geometría: El Volante 1, con su forma discoidal, alcanzó una convergencia más rápida y presentó una mejor calidad numérica. Esto se puede atribuir a su simetría y superficies regulares, que facilitan los cálculos. En cambio, el Volante 2, con forma cónica, es más complejo desde el punto de vista numérico, pero ofrece representaciones más naturales y agradables a la vista. Por su parte, el Volante 3, con forma semicilíndrica, logró el mejor balance general entre calidad y desempeño.

Escalabilidad y ganancias: El Volante 3 mostró una mejora constante a medida que aumentaba el número de iteraciones. Desde 3,000 hasta 30,000 iteraciones, obtuvo una ganancia total de +5.16 dB, la mayor mejora entre los tres modelos, lo que confirma que tiene una excelente escalabilidad y sigue mejorando con más tiempo de entrenamiento.

Calidad visual: La inspección visual confirma que todos los modelos alcanzan fidelidad suficiente para aplicaciones arqueológicas, con texturas bien definidas y geometrías reconocibles después de 30,000 iteraciones.

Estos resultados establecen una base sólida para las evaluaciones técnicas y científicas que se presentan en las siguientes secciones, donde se analizarán en profundidad los aspectos computacionales y la relevancia arqueológica de los modelos generados.

7 Conclusiones

Este anexo presentó las generalidades de 3DGS y su aplicación al modelado 3D de volantes de huso de la Ceramoteca del Museo de Historia Natural de la Universidad del Cauca. Los resultados son promisorios y validan las cualidades 3DGS.